

# DATA ENGINEERING ASSIGNMENT

## AdventureWorks ETL Pipeline Project

Dokumen Submission & Laporan Teknis

Lengkapi tabel identitas berikut sebelum mengisi bagian lainnya.

| Field                | Isi                                           |
|----------------------|-----------------------------------------------|
| Nama Lengkap         | Dinda Raraswati                               |
| ID Siswa             |                                               |
| Batch / Kelas        | Data Engineering Batch 15                     |
| Case yang Dikerjakan | Case 3 (Customer Segmentation & RFM Analysis) |
| Filter               | Territory: Northwest & Southwest              |
| Tanggal Submit       | 18 September 2026                             |



### Instruksi Umum

- Dokumen ini wajib diisi lengkap dan dikumpulkan bersama file .py dan .sql kamu.
- Setiap pertanyaan harus dijawab dengan kata-katamu sendiri — bukan copy dari internet atau AI.
- Screenshot Airflow UI dan DBeaver wajib disertakan di bagian akhir dokumen.
- filter** yang kamu gunakan harus sesuai dengan yang diberikan oleh instruktur.

| Komponen Penilaian          | Bobot | Catatan                  |
|-----------------------------|-------|--------------------------|
| Kelengkapan dokumen ini     | 20%   | Semua field terisi       |
| Kebenaran kode ETL (.py)    | 30%   | DAG berjalan tanpa error |
| Kebenaran output SQL (.sql) | 20%   | Hasil query sesuai       |
| Screenshot & bukti run      | 15%   | Airflow + DBeaver        |
| Code walk-through           | 15%   | Bisa jelaskan kodenya    |

## Bagian A — Desain & Pemahaman

### A1. Business Question

Tuliskan business question yang menjadi dasar pipeline ETL kamu (dengan kata-katamu sendiri):

|                                                                                                                               |
|-------------------------------------------------------------------------------------------------------------------------------|
| Siapa top 10 customer yang berharga bagi perusahaan?                                                                          |
| Bagaimana distribusi customer segment di territory Northwest dan Southwest?                                                   |
| Bagaimana profil masing-masing customer segment di territory Northwest dan Southwest?                                         |
| Siapa kandidat yang berpotensi untuk win-back campaign (Customer dengan Recency > 365 hari yang masih punya Monetary tinggi)? |
| Berapa rata-rata RFM score pada masing-masing daerah?                                                                         |

### A2. Deklarasi Grain

Sebelum menulis kode, kamu harus mendeklarasikan grain dari setiap tabel. Isi tabel berikut:

| Tabel                   | Grain (1 baris = ?)                | Alasan                                                                                                                                                                                          |
|-------------------------|------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| dwh.stg_customer_orders | 1 baris per order header (orderID) | Informasi 1 baris per OrderID dibutuhkan karena nantinya hanya membutuhkan histori per transaksi untuk menghitung RFM                                                                           |
| dwh.trf_customer_rfm    | 1 baris per customer               | Dalam customer segmentation dan RFM analysis, data yang dibutuhkan adalah frekuensi, waktu terakhir, dan berapa banyak jumlah uang yang dikeluarkan <b>per customer</b> dalam histori transaksi |
| dwh.fact_customer_rfm   | 1 baris per customer               | Analisa yang diinginkan adalah histori per customer                                                                                                                                             |

 Grain = definisi 1 baris di tabel tersebut merepresentasikan apa. Contoh: '1 baris = 1 transaksi per produk per order'.

### A3. Source to Target Mapping

Jelaskan tabel source mana saja yang kamu gunakan dan JOIN apa yang kamu lakukan:

**Tahapan Extract 1:** membuat CTE terpisah untuk customer\_cte (berisi informasi terkait customer) dan sales\_cte (informasi terkait penjualan) sebelum akhirnya digabungkan menjadi 1 table, yaitu dwh.stg\_customer\_orders

| CTE          | Source Table           | Kolom Diambil                                                                                                                                           | Jenis Join                                                                                                                                                                                                                                                                                           | Target Kolom                                                                                                             |
|--------------|------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|
| sales_cte    | Sales.SalesOrderHeader | SalesOrderID<br>OrderDate<br>CustomerID<br>TerritoryID                                                                                                  | FROM Sales.SalesOrderHeader<br>lalu INNER JOIN dengan semua source tables<br><br><ul style="list-style-type: none"> <li>SalesOrderHeader dan SalesOrderDetail dijoin menggunakan kolom "SalesOrderID"</li> <li>SalesOrderHeader dan SalesTerritory dijoin menggunakan kolom "TerritoryID"</li> </ul> | SalesOrderID<br>OrderDate<br>CustomerID<br>TerritoryID<br>LineTotal<br>TerritoryID<br>TerritoryName<br>CountryRegionCode |
|              | Sales.SalesOrderDetail | Pada source table ini, dilakukan agregat perhitungan total spending sendiri dengan rumus :<br>SUM("OrderQty" * "UnitPrice" * (1 - "UnitPriceDiscount")) |                                                                                                                                                                                                                                                                                                      |                                                                                                                          |
|              | Sales.SalesTerritory   | Name<br>CountryRegionCode                                                                                                                               |                                                                                                                                                                                                                                                                                                      |                                                                                                                          |
| customer_cte | Sales.Customer         | CustomerID<br>PersonID                                                                                                                                  | FROM Customer LEFT JOIN Person                                                                                                                                                                                                                                                                       | CustomerID<br>PersonID<br>CustomerName                                                                                   |
|              | Person.Person          | FirstName +<br>MiddleName +<br>LastName<br>dicombined untuk membentuk CustomerName                                                                      |                                                                                                                                                                                                                                                                                                      |                                                                                                                          |

Pada sales\_cte, INNER JOIN dipilih karena data transaksi yang dibutuhkan untuk menghitung RFM adalah transaksi yang memiliki semua nilai seperti informasi daerah, tanggal order, dan total amount yang dikeluarkan. Pada customer\_cte, LEFT JOIN dipilih karena data customer yang lebih dibutuhkan dalam study case ini.

**Tahapan Extract 2:** menggabungkan sales\_cte dan customer\_cte

| CTE          | Kolom                                                                                                                    | Jenis Join                                                           | Target Kolom                                                                                                                                         |
|--------------|--------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| sales_cte    | SalesOrderID<br>OrderDate<br>CustomerID<br>TerritoryID<br>LineTotal<br>TerritoryID<br>TerritoryName<br>CountryRegionCode | FROM sales_cte<br>LEFT JOIN<br>customer_cte pada<br>kolom CustomerID | SalesOrderID<br>OrderDate<br>CustomerID<br>PersonID<br>CustomerName<br>TerritoryID<br>LineTotal<br>TerritoryID<br>TerritoryName<br>CountryRegionCode |
| customer_cte | CustomerID<br>PersonID<br>CustomerName                                                                                   |                                                                      |                                                                                                                                                      |

#### A4. Keputusan Desain

Jawab pertanyaan-pertanyaan berikut dengan singkat dan jelas:

##### Kolom yang dibawa vs dibuang

Sebutkan minimal 2 kolom dari source yang TIDAK kamu bawa ke tabel fact, dan jelaskan alasannya:

Kolom yang Dibawa

| Source Table           | Kolom Diambil                                              |
|------------------------|------------------------------------------------------------|
| Sales.SalesOrderHeader | SalesOrderID<br>OrderDate<br>CustomerID<br>TerritoryID     |
| Sales.SalesOrderDetail | SalesOrderID<br>OrderQty<br>UnitPrice<br>UnitPriceDiscount |
| Sales.SalesTerritory   | Name<br>CountryRegionCode                                  |
| Sales.Customer         | CustomerID<br>PersonID                                     |
| Person.Person          | FirstName<br>MiddleName<br>LastName                        |

### Kolom yang Dibuang

| Source Table               | Nama Kolom                                 | Alasan Dibuang                                                                                                                                                                  |
|----------------------------|--------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Sales<br>.SalesOrderDetail | LineTotal                                  | Kolom ini dibuang karena semua nilai di kolom ini adalah NULL Values, padahal kolom ini penting untuk menghitung monetary                                                       |
|                            | SalesOrderDetailID                         | Kolom ini dibuang karena grain yang digunakan pada dwh.stg_customer_orders adalah 1 baris per order header (orderId)                                                            |
| Sales.SalesOrderHeader     | OrderDate<br>DueDate<br>ShipDate<br>Status | Kolom-kolom ini dibuang karena fokus analisa adalah customer segmentation.<br>Kolom-kolom ini dipertahankan hanya jika analisa yang dilakukan berupa performa pengiriman barang |

### Handling NULL

Kolom mana saja yang berpotensi NULL di data kamu? Bagaimana kamu menanganinya?

Kolom CustomerName pada fact table berpotensi memiliki nilai NULL. Hal ini disebabkan karena PersonID pada source table Sales.Customer bernilai NULL untuk B2B customer tanpa kontak personal sehingga bisa menghasilkan NULL ketika dijoin dengan table Person.Person. Untuk mengatasi hal ini, digunakan COALESCE pada CustomerName:

```
COALESCE(p."FirstName", '') || ' ' || COALESCE(p."MiddleName", '') || ' ' || COALESCE(p."LastName", ' ') AS "CustomerName"
```

### Pattern Load

Kamu menggunakan pattern TRUNCATE → INSERT (full refresh). Kapan pattern ini TIDAK cocok dipakai?

Pattern ini tidak cocok digunakan ketika volume data semakin bertambah besar. Hal ini karena akan memakan lebih banyak waktu dan resource untuk terus menghapus dan mengekstraksi data dari awal lagi. Apalagi jika penambahan data baru hanya sedikit, khususnya pada kasus real-time yang hanya sedikit penambahan data barunya. Selain itu, truncate ini juga tidak melakukan SCD sehingga tidak dapat menyimpan data histori seperti perubahan data customer.

## Bagian B — Implementasi ETL

### B1. Checklist File yang Dikumpulkan

| No | Item                                                           | Status (✓/✗) |
|----|----------------------------------------------------------------|--------------|
| 1  | dag_[nama_case]_[nama_kamu].py — file DAG Airflow              | ✓            |
| 2  | analytic_queries_[nama_case].sql — minimal 3 analytic query    | ✓            |
| 3  | Dokumen submission ini (diisi lengkap)                         | ✓            |
| 4  | Screenshot DAG Graph View (Airflow UI)                         | ✓            |
| 5  | Screenshot Task Log task 'extract' — terlihat jumlah baris     | ✓            |
| 6  | Screenshot Task Log task 'transform' — terlihat jumlah baris   | ✓            |
| 7  | Screenshot Task Log task 'load' — terlihat jumlah baris        | ✓            |
| 8  | Screenshot tabel fact_* di DBeaver — minimal 10 baris terlihat | ✓            |

### B2. Penjelasan Pipeline

Jelaskan alur pipeline kamu dari awal sampai akhir dalam 5-8 kalimat:

Alur pipeline dimulai dari menghubungkan koneksi ke 'adventure\_works' yang memiliki semua source tables yang dibutuhkan. Setelah itu, proses selanjutnya adalah extract yang mengambil informasi customer serta detail order yang kemudian data ini dimasukkan ke dalam dwh.stg\_customer\_orders. Proses dilanjutkan ke transform yang bertugas untuk menghitung R,F,M, dan RFM score serta customer segmen. Hasil dari transform disimpan ke dwh.trf\_customer\_rfm. Tahap terakhir adalah load yang menggunakan data dari dwh.trf\_customer\_rfm dan hanya menambahkan LoadTimestamp.

### B3. Pertanyaan Teknis

#### B3.1 Apa yang terjadi kalau DAG dijalankan 2x berturut-turut?

Apakah datanya duplikat, tetap sama, atau error? Jelaskan kenapa:

Data akan tetap sama karena DAG ini menggunakan truncate sehingga data yang sebelumnya diekstraksi akan terhapus dan digantikan oleh data yang diekstraksi lagi

#### B3.2 Apa fungsi conn\_id 'adventure\_works' di kode kamu?

Di mana conn\_id ini didaftarkan, dan apa yang terjadi kalau conn\_id salah?

Fungsi conn\_id 'adventure\_works' adalah untuk memanggil detail koneksi untuk menyambungkan airflow dengan Postgres sumber data yang digunakan. Jika conn\_id ini salah, maka akan terjadi error pada airflow dan airflow tidak akan terhubung dengan sumber data yang digunakan

## Bagian C — Analytic Queries

Kamu wajib membuat minimal 3 analytic query dari tabel fact yang sudah kamu buat. Dokumentasikan di sini.

### Query 1

Business Question yang dijawab:

Siapa top 10 customer yang berharga bagi perusahaan? (segment = champions)

SQL Query:

```
SELECT
  "CustomerName"
  , "TerritoryName"
  , "Recency"
  , "Frequency"
  , "Monetary"
  , "RFM_Score"
  , "Segment"
FROM "dwh"."fact_customer_rfm"
WHERE "Segment" = 'Champions'
ORDER BY "RFM_Score" DESC, "Monetary" DESC
LIMIT 10;
```

Hasil / Insight yang ditemukan:

| SELECT "CustomerName", "TerritoryName", "Recency" Enter a SQL expression to filter results (use Ctrl+Space) |                       |                  |             |               |              |               |            |  |
|-------------------------------------------------------------------------------------------------------------|-----------------------|------------------|-------------|---------------|--------------|---------------|------------|--|
| Grid                                                                                                        | AZ CustomerName       | AZ TerritoryName | 123 Recency | 123 Frequency | 123 Monetary | 123 RFM_Score | AZ Segment |  |
| 1                                                                                                           | Roger Harui           | Northwest        | 91          | 12            | 877,107.2    | 12            | Champions  |  |
| 2                                                                                                           | Blaine Dockter        | Southwest        | 91          | 12            | 693,502.49   | 12            | Champions  |  |
| 3                                                                                                           | Kevin Liu             | Southwest        | 60          | 8             | 636,226.46   | 12            | Champions  |  |
| 4                                                                                                           | John Arthur           | Southwest        | 91          | 12            | 618,616.13   | 12            | Champions  |  |
| 5                                                                                                           | Lola M. McCarthy      | Northwest        | 91          | 8             | 536,546.13   | 12            | Champions  |  |
| 6                                                                                                           | Patricia M. Vasquez   | Northwest        | 91          | 8             | 477,957.27   | 12            | Champions  |  |
| 7                                                                                                           | Robert M. Bernacchi   | Northwest        | 60          | 8             | 443,316.1    | 12            | Champions  |  |
| 8                                                                                                           | John Kelly            | Southwest        | 91          | 12            | 427,890.84   | 12            | Champions  |  |
| 9                                                                                                           | Cheryl M. Herring     | Southwest        | 60          | 12            | 424,512.7    | 12            | Champions  |  |
| 10                                                                                                          | Elizabeth J. Sullivan | Southwest        | 60          | 8             | 418,436.54   | 12            | Champions  |  |

- Customer dari daerah Southwest mendominasi top 10 customer yang paling berharga bagi perusahaan. Hal ini menunjukkan bahwa daerah Southwest merupakan daerah yang potensial dalam pengembangan bisnis ke depannya
- Roger Harui merupakan customer dengan total monetary tertinggi (877.107,2 USD) jauh lebih tinggi dibandingkan customer lainnya pada top 10 customer. Roger juga memiliki frekuensi sangat tinggi, yaitu 12 kali. Hal ini menunjukkan bahwa orang ini

sangat berharga bagi perusahaan sehingga perusahaan butuh mempertahankan engagement customer ini. Perlu dicatat pula bahwa Roger Harui tercatat melakukan transaksi 3 bulan dari tanggal maksimum dataset (30 Juni 2024). Perusahaan perlu melakukan re-engagement dengan customer ini

Query 2

Business Question yang dijawab:

Bagaimana distribusi customer segment di territory Northwest dan Southwest?

SQL Query:

```
SELECT
    "Segment"
    , COUNT(DISTINCT "CustomerID") AS "Number of Customers"
    , ROUND(COUNT(DISTINCT "CustomerID") * 100.0 / (SELECT COUNT(*) FROM
    "dwh"."fact_customer_rfm"),2) as "percentage"
FROM "dwh"."fact_customer_rfm"
GROUP BY 1;
```

Hasil / Insight yang ditemukan:

SELECT "Segment" , COUNT(DISTINCT "Cust" Enter a SQL expression to filter results (

| Grid |  | A-Z Segment | 123 Number of Customers | 123 percentage |
|------|--|-------------|-------------------------|----------------|
| 1    |  | At Risk     | 2,083                   | 26.06          |
| 2    |  | Loyal       | 3,884                   | 48.59          |
| 3    |  | Champions   | 1,536                   | 19.22          |
| 4    |  | Lost        | 490                     | 6.13           |

- Customer loyal ternyata mencakup hampir 50% dari keseluruhan customer perusahaan Adventure Works. Hal ini sangat baik bagi perusahaan karena kelompok customer ini memiliki frekuensi pembelian yang sering dengan total monetary yang juga lumayan baik. Perusahaan dapat melakukan teknik marketing pada kelompok customer ini untuk meningkatkan pembelian mereka dengan menawarkan upselling ataupun bundling produk
- Kelompok “At Risk” juga ternyata cukup tinggi. Perusahaan dapat melakukan re-engagement terhadap kelompok customer ini dengan mengirimkan notifikasi belanja atau menawarkan diskon

### Query 3

#### Business Question yang dijawab:

Bagaimana profil masing-masing customer segment di territory Northwest dan Southwest?

#### SQL Query:

```
SELECT
    "Segment"
    , MAX("Recency") as "max_recency"
    , ROUND(AVG("Recency"),2) as "avg_recency"
    , MIN("Recency") as "min_recency"
    , MAX("Frequency") as "max_frequency"
    , ROUND(AVG("Frequency"),2) as "avg_frequency"
    , MIN("Frequency") as "min_frequency"
    , MAX("Monetary") as "max_monetary"
    , ROUND(AVG("Monetary"),2) as "avg_monetary"
    , MIN("Monetary") as "min_monetary"
FROM "dwh"."fact_customer_rfm"
GROUP BY 1;
```

#### Hasil / Insight yang ditemukan:

| SELECT "Segment" , MAX("Recency") as "max_recency" , ROUND(AVG("Recency"),2) as "avg_recency" , MIN("Recency") as "min_recency" , MAX("Frequency") as "max_frequency" , ROUND(AVG("Frequency"),2) as "avg_frequency" , MIN("Frequency") as "min_frequency" |            |                 |                 |                 |                   |                   |                   |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------|-----------------|-----------------|-----------------|-------------------|-------------------|-------------------|
| Grid                                                                                                                                                                                                                                                       | AZ Segment | 123 max_recency | 123 avg_recency | 123 min_recency | 123 max_frequency | 123 avg_frequency | 123 min_frequency |
| 1                                                                                                                                                                                                                                                          | At Risk    | 1,122           | 334.58          | 0               | 2                 | 1                 | 1                 |
| 2                                                                                                                                                                                                                                                          | Champions  | 276             | 120.47          | 0               | 12                | 2.38              | 1                 |
| 3                                                                                                                                                                                                                                                          | Loyal      | 911             | 154.85          | 0               | 8                 | 1.18              | 1                 |
| 4                                                                                                                                                                                                                                                          | Lost       | 365             | 320.91          | 277             | 1                 | 1                 | 1                 |

| 123 max_monetary | 123 avg_monetary | 123 min_monetary |
|------------------|------------------|------------------|
| 3,578.27         | 748.35           | 2.29             |
| 877,107.2        | 19,240.29        | 42.28            |
| 585,516.44       | 2,354.7          | 2.29             |
| 41.93            | 24.51            | 2.29             |

- Jika melihat karakteristik recency, dapat terlihat bahwa hampir semua kelompok customer memiliki recency terendah yang mirip (0 hari dari tanggal maksimum dataset), hanya kelompok Lost yang memiliki minimum recency mencapai 277 hari. Rata-rata recency pada kelompok "Lost" tertinggi dibandingkan kelompok customer lainnya meskipun menariknya kelompok Lost ini memiliki maximum recency yang relatif rendah dibandingkan At Risk dan Loyal. Pola ini juga menunjukkan bahwa

perbedaan recency antar kelompok customer tidak terlalu besar, maksimal hanya <6 bulan untuk Lost dan Champions

- Jika melihat karakteristik, dapat terlihat bahwa rata-rata frekuensi belanja pada kelompok customer selain Champions adalah 1 kali. Selain itu, meskipun rata-rata frekuensi pembelian pada kelompok Champions hanya beda tipis dengan kelompok lainnya (~2 kali), terdapat beberapa customer yang menjadi anomali dengan frekuensi pembelian hingga 12 kali. Champion customers dengan frekuensi pembelian 12 kali juga diperlihatkan pada top 10 customer berharga bagi perusahaan di nomor 1
- Jika melihat karakteristik monetary, dapat terlihat bahwa karakteristik inilah penentu segmen "Champions". Hal ini disebabkan karena pada karakteristik lainnya (recency dan frequency), kelompok Champions tidak memperlihatkan perbedaan yang jauh dengan kelompok lainnya. Namun total monetary kelompok Champions (19.240,29 USD) sangat jauh dibandingkan kelompok lainnya (<3.000 USD). Kelompok Lost hanya memiliki rata-rata 23,14 USD. Hal ini menunjukkan bahwa perusahaan tidak perlu melakukan effort apapun pada kelompok customer ini

#### Query 4

#### Business Question yang dijawab:

Siapa kandidat yang berpotensi untuk win-back campaign (Customer dengan Recency > 365 hari yang masih punya Monetary tinggi)?

#### SQL Query:

```
SELECT
  "CustomerName"
  , "TerritoryName"
  , "Recency"
  , "Frequency"
  , "Monetary"
FROM "dwh"."fact_customer_rfm"
WHERE "Recency" > 365
ORDER BY 5 desc
LIMIT 10;
```

#### Hasil / Insight yang ditemukan:

| fact_customer_rfm 1 X                                                                                       |                   |                  |             |               |              |  |
|-------------------------------------------------------------------------------------------------------------|-------------------|------------------|-------------|---------------|--------------|--|
| SELECT "CustomerName", "TerritoryName", "Recency" Enter a SQL expression to filter results (use Ctrl+Space) |                   |                  |             |               |              |  |
| Grid                                                                                                        | AZ CustomerName   | AZ TerritoryName | 123 Recency | 123 Frequency | 123 Monetary |  |
| 1                                                                                                           | Steven B. Brown   | Southwest        | 426         | 8             | 585,516.44   |  |
| 2                                                                                                           | Stefan Delmarco   | Southwest        | 457         | 8             | 413,054.82   |  |
| 3                                                                                                           | David Johnson     | Northwest        | 457         | 8             | 387,118.34   |  |
| 4                                                                                                           | Jane A. McCarty   | Southwest        | 426         | 4             | 354,805.25   |  |
| 5                                                                                                           | Juanita J. Holman | Southwest        | 457         | 8             | 311,446.43   |  |
| 6                                                                                                           | Jean Jordan       | Southwest        | 487         | 8             | 286,972.08   |  |
| 7                                                                                                           | Michael Graff     | Southwest        | 426         | 4             | 268,209.29   |  |
| 8                                                                                                           | Teresa Atkinson   | Southwest        | 791         | 4             | 261,522.32   |  |
| 9                                                                                                           | Brenda Diaz       | Northwest        | 791         | 4             | 243,014.55   |  |
| 10                                                                                                          | Joy R. Koski      | Northwest        | 791         | 4             | 193,258.67   |  |

- Steven B. Brown, Stefan Delmarco, dan David Johnson merupakan tiga customer dengan recency >365 hari, namun memiliki frekuensi pembelian dan monetary yang tinggi sehingga ketiga customer ini dapat ditawarkan win back campaign

### Query 5

#### Business Question yang dijawab:

Berapa rata-rata RFM score pada masing-masing daerah?

#### SQL Query:

```
SELECT
  "TerritoryName"
  , ROUND(AVG("RFM_Score"),2) as "avg_rfm"
FROM "dwh"."fact_customer_rfm"
GROUP BY 1;
```

#### Hasil / Insight yang ditemukan:

| fact_customer_rfm 1 X                             |                  |             |  |
|---------------------------------------------------|------------------|-------------|--|
| SELECT "TerritoryName", ROUND(AVG   Enter a SQL e |                  |             |  |
| Grid                                              | AZ TerritoryName | 123 avg_rfm |  |
| 1                                                 | Northwest        | 7.42        |  |
| 2                                                 | Southwest        | 7.56        |  |

- Daerah Northwest dan Southwest memiliki rata-rata RFM score yang mirip. Hal ini menunjukkan bahwa meskipun daerah Southwest sedikit lebih unggul dibandingkan Northwest, tapi sebenarnya profil customer di kedua daerah ini cukup mirip

## Bagian D — Refleksi & Pengembangan

### D1. Tantangan yang Dihadapi

Ceritakan minimal 1 error atau bug yang kamu temui saat mengerjakan project ini dan bagaimana kamu mengatasinya:

Error yang didapatkan selama mengerjakan tugas ini adalah saat check\_connection. Berulang kali mendapatkan error ini, padahal informasi connection adventure\_works di airflow sudah sesuai dengan yang di notion hands-on. Untuk mengatasi hal ini, saya melakukan debugging pada logs dan mendapatkan error salah password. Saya pun akhirnya edit connectionnya lagi mulai dari ganti port dari 5433 ke 5432, tapi tetap gagal. Akhirnya, saya dibantu AI bisa menemukan letak kesalahannya, yaitu portnya harus 5434

### D2. Limitasi Pipeline Kamu

Pipeline yang kamu buat saat ini punya keterbatasan. Sebutkan minimal 2 hal yang TIDAK bisa dijawab dari tabel fact kamu, dan jelaskan kenapa:

1. Tabel fact ini tidak memiliki min\_date dan max\_date per customer, padahal jika mengetahui min\_date dan max\_date dapat dilakukan cohort analysis untuk menginvestigasi pola retention rate per periode
2. Tabel fact ini hanya berfokus pada dua daerah (Northwest dan Southwest) sehingga tidak bisa menjawab pertanyaan bisnis terkait pola customer segmentation di daerah lain

### D3. Pengembangan Selanjutnya

Kalau kamu punya lebih banyak waktu, apa yang akan kamu tambahkan atau perbaiki dari pipeline ini? (minimal 2 ide)

1. Menambahkan dbt untuk data modelling agar data model yang dibuat bisa dilakukan data quality testing
2. Saat ini extract cuma menghasilkan 1 table. Ke depannya jika punya banyak waktu ingin menggunakan medallion architecture : semua raw data dimasukkan ke bronze layer, semua nantinya ditransformasi di silver layer, dan baru buat fact serta dimension tables

## D4. Pernyataan Integritas

*Saya menyatakan bahwa seluruh isi dokumen ini, kode yang saya kumpulkan, dan jawaban yang saya berikan adalah hasil kerja saya sendiri.*

*Saya memahami setiap baris kode yang saya tulis dan siap menjelaskannya.*

**Nama :**


Dinda Raraswati

---

## Bagian E — Screenshot & Bukti

Tempelkan screenshot di bawah ini. Setiap screenshot harus menunjukkan nama kamu atau territory filter yang unik sebagai bukti bahwa ini hasil run kamu sendiri.

### Screenshot 1 — DAG Graph View (Airflow UI)



### Screenshot 2 — Task Log 'extract' + 'transform' + 'load'

#### Task log extract

```
682a1b4f7f24
*** Found local files:
*** /opt/airflow/logs/dag_id=customer_rfm/run_id=manual__2026-09-17T14:00:29.906648+00:00/task_id=extract/attempt=1.log
[2026-09-17, 14:00:31 UTC] [local_task_job_runner.py:120] ▶ Pre task execution logs
[2026-09-17, 14:00:31 UTC] [base.py:84] INFO - Using connection ID 'adventure_works' for task execution.
[2026-09-17, 14:00:31 UTC] [logging_mixin.py:188] INFO - [extract] stg_customer_orders has been extracted. There are 10818 rows
[2026-09-17, 14:00:31 UTC] [python.py:237] INFO - Done. Returned value was: None
[2026-09-17, 14:00:31 UTC] [taskinstance.py:441] ▶ Post task execution logs
```

#### Task log transform

```
682a1b4f7f24
*** Found local files:
*** /opt/airflow/logs/dag_id=customer_rfm/run_id=manual__2026-09-17T14:00:29.906648+00:00/task_id=load/attempt=1.log
[2026-09-17, 14:00:33 UTC] [local_task_job_runner.py:120] ▶ Pre task execution logs
[2026-09-17, 14:00:33 UTC] [base.py:84] INFO - Using connection ID 'adventure_works' for task execution.
[2026-09-17, 14:00:33 UTC] [logging_mixin.py:188] INFO - [load] Successfully load 7993 rows to dwh.fact_customer_rfm.
[2026-09-17, 14:00:33 UTC] [python.py:237] INFO - Done. Returned value was: None
[2026-09-17, 14:00:33 UTC] [taskinstance.py:441] ▶ Post task execution logs
```

#### Task log load

```
682a1b4f7f24
*** Found local files:
*** /opt/airflow/logs/dag_id=customer_rfm/run_id=manual__2026-09-17T14:00:29.906648+00:00/task_id=load/attempt=1.log
[2026-09-17, 14:00:33 UTC] [local_task_job_runner.py:120] ▶ Pre task execution logs
[2026-09-17, 14:00:33 UTC] [base.py:84] INFO - Using connection ID 'adventure_works' for task execution.
[2026-09-17, 14:00:33 UTC] [logging_mixin.py:188] INFO - [load] Successfully load 7993 rows to dwh.fact_customer_rfm.
[2026-09-17, 14:00:33 UTC] [python.py:237] INFO - Done. Returned value was: None
[2026-09-17, 14:00:33 UTC] [taskinstance.py:441] ▶ Post task execution logs
```

| Screenshot 3 — Tabel fact_* di DBeaver (minimal 10 baris) |                  |                  |             |               |              |             |             |             |               |  |
|-----------------------------------------------------------|------------------|------------------|-------------|---------------|--------------|-------------|-------------|-------------|---------------|--|
| customerID                                                | AZ CustomerName  | AZ TerritoryName | 123 Recency | 123 Frequency | 123 Monetary | 123 R_Score | 123 F_Score | 123 M_Score | 123 RFM_Score |  |
| 1                                                         | Sydney C Rogers  | Southwest        | 1,122       | 1             | 3,578.27     | 1           | 2           | 4           |               |  |
| 2                                                         | Lucas Hill       | Southwest        | 1,121       | 1             | 3,578.27     | 1           | 2           | 4           |               |  |
| 5                                                         | Alyssa L Garcia  | Southwest        | 1,118       | 1             | 3,578.27     | 1           | 2           | 4           |               |  |
| 1                                                         | Garrett C Cooper | Southwest        | 1,118       | 1             | 3,399.99     | 1           | 2           | 4           |               |  |
| 7                                                         | Patrick K Cook   | Northwest        | 1,118       | 1             | 3,578.27     | 1           | 2           | 4           |               |  |
| 4                                                         | Richard Brooks   | Northwest        | 1,117       | 1             | 3,578.27     | 1           | 2           | 4           |               |  |
| 3                                                         | Courtney Carter  | Southwest        | 1,110       | 1             | 3,578.27     | 1           | 2           | 4           |               |  |
| 9                                                         | Evan C Bailey    | Northwest        | 1,108       | 1             | 3,578.27     | 1           | 2           | 4           |               |  |
| 4                                                         | Warren Ye        | Northwest        | 1,108       | 1             | 3,578.27     | 1           | 2           | 4           |               |  |
| 7                                                         | Abigail M Perry  | Northwest        | 1,105       | 1             | 3,399.99     | 1           | 2           | 4           |               |  |

| 123 RFM_Score | AZ Segment | ⌚ LoadTimeStamp         |
|---------------|------------|-------------------------|
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |
| 7             | Loyal      | 2026-09-18 13:43:27.730 |